

TP3 - Índice invertido

Iniciar tarefa

- Vencimento Quarta-feira por 23:59
- Pontos 5
- Enviando um URL de site ou uma gravação de mídia
- Disponível até 3 jun em 23:59

O terceiro trabalho prático da disciplina também envolverá implementar as buscas por cursos por meio de palavras (termos) do nome destes cursos.

ÍNDICE INVERTIDO

O índice invertido nos permite fazer buscas por entidades a partir de seus termos (palavras). Para isso, a gente precisa criar uma lista de IDs para cada termo indexado. Por exemplo, suponha que os seguintes cursos estejam cadastrados:

ID	Nome
1	Introdução à Inteligência Artificial
2	Inteligência Emocional para Gestores
3	Inteligência no Trabalho por Meio da Inteligência Artificial
4	Introdução à Gestão de Equipes

A criação das listas começa com a inserção do primeiro curso. Ao criá-lo, as palavras do nome (ou outro atributo) devem ser transformadas em um vetor de palavras. Em seguida, as palavras irrelevantes para as buscas, como os artigos, as preposições e os numerais devem ser descartados desse vetor. Essas palavras irrelevantes são chamadas de *stop words* (palavras vazias). Você podem encontrar listas de *stop words* em português na Internet. Em seguida, é necessário aplicar uma transformação para que as palavras restantes fiquem em letras minúsculas e sem acentos. Por exemplo, para o primeiro curso, o seguinte vetor será gerado: ["introducao", "inteligencia", "artificial"].

Empregando a lógica do valor $TF \times IDF$ (<https://pt.wikipedia.org/wiki/TF%E2%80%93IDF>) (Term Frequency – Inverse Document Frequency), o próximo passo é determinar a frequência do termo no nome do curso e qual o inverso da frequência do termo entre os cursos. O valor TF indica a taxa de ocorrências de um determinado termo no nome. Por exemplo, para o primeiro curso, o termo "introducao" aparece uma vez de um total de três termos ($33.3\% = 0.333$). Já para o terceiro curso, o termo "inteligencia" aparece 2 vezes em cinco palavras (após descartar as *stop words*) e sua frequência é, portanto, 0.4 (40%).

Já o IDF indica o inverso da taxa de ocorrências de um termo entre os nomes (ou entre as entidades). Por exemplo, o termo "inteligencia" aparece em 3 dos 4 cursos. Como buscamos o inverso dessa taxa, o IDF desse termo será $4/3 = 1.333$. No entanto, para equilibrarmos os resultados, aplicaremos a função logaritmo (base 10) a esse valor e somaremos o valor 1 ao resultado, para que todas as respostas sejam acima de 1. Assim, o IDF do termo será efetivamente: $\log(4/3) + 1 = 1.125$

Após a inserção de todos os cursos, chegaremos às seguintes listas invertidas:

```
- introducao: (1; 0.333), (4; 0.333)
- artificial: (1; 0.333), (3; 0.2)
- inteligencia: (1; 0.333), (2; 0.333), (3; 0.4)
- emocional: (2; 0.333)
- gestores: (2; 0.333)
- trabalho: (3; 0.2)
- meio: (3; 0.2)
- gestao: (4; 0.333)
- equipes: (4; 0.333)
```

Note que as frequências foram registradas como uma taxa das palavras válidas (que não são *stop words*). Nessas listas não aparecem os valores de *IDF*, mas apenas os valores de *TF*. Mas sabemos que temos 4 cursos (que devem estar armazenado em algum outro arquivo) e sabemos o tamanho de cada lista. Assim, podemos calcular o *IDF* a qualquer hora.

Para fazermos a consulta em uma lista assim, precisamos pedir ao usuário que digite os termos de busca. Por exemplo, suponha que ele digita: "Inteligência Artificial". Quando fizermos o mesmo tratamento que fizemos com os nomes dos cursos, chegaremos ao vetor `["inteligencia", "artificial"]`. Em seguida, recuperamos a lista de cada termo e multiplicamos os valores de *TF* pelos valores de *IDF* dos termos. O *IDF* do termo "inteligencia" é 1.125, calculado por meio da função $\log(4/3)+1$ e do termo "artificial" é 1.301, calculado por meio de $\log(4/2)+1$. Assim, os valores recuperados já multiplicados pelos *IDFs* serão:

```
- inteligencia: [(1; 0.375), (2; 0.375), (3; 0.45)]
- artificial: [(1; 0.433), (3; 0.206)]
```

Finalmente, geramos uma única lista com os valores que tenham o mesmo *ID* somados:

```
[(1; 0.808), (2; 0.375), (3; 0.656)]
```

Ao ordenarmos essa lista pelo valor de cada *ID*, teremos a seguinte lista: `[1, 3, 2]`. O curso de *ID* 4 não aparece na lista, porque não tem nenhum dos termos da busca. Assim, os cursos serão apresentados nessa ordem para os usuários. Em um sistema real, geralmente as respostas são apresentadas de 10 em 10 (como no Google).

Neste projeto, vocês devem implementar o índice invertido e a busca exatamente como descrito acima. Lembre-se de que o índice invertido usará as listas invertidas cujo código está disponível  <https://github.com/kutova/AEDsIII/tree/main/ListaInvertida>. Nesse exemplo, elas devem ser atualizadas sempre que um curso for incluído, excluído ou tiver seu nome alterado.

O QUE DEVE SER FEITO?

- Implementar o índice invertido  <https://github.com/kutova/AEDsIII/tree/main/ListaInvertida> para os cursos usando as palavras dos nomes dos cursos.
- Implementar a busca de cursos por palavras oferecendo respostas ordenadas pelo valor $TF \times IDF$.

Quanto tudo estiver pronto, as buscas por cursos deverão ser por código compartilhável do curso e por palavras-chave do nome do curso.

FORMA DE ENTREGA

- **Código** - Vocês devem postar o seu trabalho no GitHub (<https://replit.com/>) e enviar apenas o URL do seu projeto. Criem um repositório específico para este projeto (ao invés de mandar o repositório pessoal de algum de vocês em que estejam todos os seus códigos). Acrescentem um arquivo `readme.md` ao projeto que será o relatório do trabalho de vocês (explicado abaixo).
- **Relatório** - O relatório deve começar com a **lista dos participantes** do trabalho prático e, em seguida, ter uma **descrição completa** do que o sistema faz. Capturem algumas telas e citem os nomes das classes que foram criadas. Expliquem todas as operações especiais que foram implementadas. O objetivo é que vocês facilitem ao máximo a minha correção, de tal forma que eu possa entender com facilidade tudo aquilo que fizeram e dar uma nota justa. No relatório, vocês devem, necessariamente, responder ao seguinte **checklist** (copie as perguntas abaixo para o seu relatório e responda sim/não em frente a elas, justificando a resposta quando necessário):
 - O índice invertido com os termos dos nomes dos cursos foi criado usando a classe `ListaInvertida`?
 - É possível buscar cursos por palavras no menu de inscrição?
 - O trabalho compila corretamente?
 - O trabalho está completo e funcionando sem erros de execução?
 - O trabalho é original e não a cópia de um trabalho de outro grupo?
- **Video de demonstração** - Grave um video de **até 3 minutos** (captura de tela com narração em áudio) mostrando as principais operações do seu sistema. Se o video ficar grande demais para o GitHub, vocês podem publicá-lo no YouTube e compartilhar o link ou usar a própria ferramenta do Canvas para captura de video.

Lembre-se de que, para essa atividade, eu avaliarei tanto o esforço quanto o resultado. Portanto, escrevam o relatório e gravem o vídeo de forma que me ajude a observar o resultado.

Atenção: As respostas incorretas ao checklist prejudicaram consideravelmente a nota do grupo. Se vocês disserem que fizeram algo que não foi implementado, a nota final será reduzida em 50% por resposta incorreta (duas respostas incorretas significam a nota zero). Além disso, se vocês disserem que algo está funcionando corretamente, mas a operação não funcionar direito, a nota final será reduzida em 25% por resposta incorreta. Dessa forma, quando necessário, justifiquem as respostas ao checklist. A falta do relatório no repositório implicará em perda de 50% dos pontos obtidos na atividade. A falta do vídeo implicará, da mesma forma, em perda de 50% dos pontos. Se os dois faltarem, a nota será, automaticamente, zero.

AValiação

Essa atividade vale 5 pontos. A avaliação será feita por meio do relatório. Dessa forma, um relatório incompleto ou ausente impactará na perda significativa de pontos na avaliação do projeto.

Atenção: Trabalhos copiados de colegas, que não evidenciem um esforço mínimo do próprio aluno, serão anulados.

Se tiver dúvidas sobre o trabalho a fazer, me avise. Não deixe de observar que o URL com o código no GitHub deve ser entregue até o dia especificado na atividade.

